

哈尔滨工业大学(深圳)

《网络与系统安全》

实验报告

实验七

对抗样本攻击 实验

学 院: 计算机科学与技术学院

姓 名: 刘睿

学 号: 220110720

专 业: 计算机科学与技术

日期: 2025 年 4 月

一、实验过程

每个实验步骤（供有 4 个任务）要求有具体截图和说明，并回答相关的问题

1. 完成所有需要补充的代码，并截图说明代码的含义和作用。

fgsm_attack()

```
1 import torch
2
3 def fgsm_attack(image, epsilon, data_grad):
4     sign_data_grad = data_grad.sign()
5     perturbed_image = image + epsilon * sign_data_grad
6     perturbed_image = torch.clamp(perturbed_image, 0, 1)
7
8     return perturbed_image
```

计算损失函数关于图像的梯度的符号，接着按照 FGSM 方法生成扰动的图像，并将像素值裁剪回 [0, 1] 范围内保证图像合法

test()

```
36 # Call FGSM Attack
37 perturbed_data = fgsm_attack(data, epsilon, data_grad)
38
39 # Re-classify the perturbed image
40 output = model(perturbed_data)
```

生成扰动后的图像并对其尝试进行分类

```
42 # Check for success
43 final_pred = output.max(1, keepdim=True)[1] # get the index of the max log-probability
44 if final_pred.item() == target.item():
45     correct += 1
46     # Special case for saving 0 epsilon examples
47     if (epsilon == 0) and (len(adv_examples) < 5):
48         adv_ex = perturbed_data.squeeze().detach().cpu().numpy()
49         adv_examples.append( (init_pred.item(), final_pred.item(), adv_ex) )
50 else:
51     # Save some adv examples for visualization later
52     if len(adv_examples) < 5:
53         adv_ex = perturbed_data.squeeze().detach().cpu().numpy()
54         adv_examples.append( (init_pred.item(), final_pred.item(), adv_ex) )
```

对于确实扰动后预测失败的图像，对每个 epsilon 下的前五张进行保存

2. 分析 4.4 测试攻击效果函数 的代码部分，说明每段代码的作用。

test()

```
1 def test(model, device, test_loader, epsilon):
2
3     # Accuracy counter
4     correct = 0
5     adv_examples = []
6
7     # Loop over all examples in test set
8     for data, target in test_loader:
9
```

correct 记录正确数量之后计算 Acc

adv_example 列表保存预测失败的例子，之后可视化

对 test_loader 进行迭代

```
7     # Loop over all examples in test set
8     for data, target in test_loader:
9
10        # Send the data and label to the device
11        data, target = data.to(device), target.to(device)
12
13        # Set requires_grad attribute of tensor. Important for Attack
14        data.requires_grad = True
15
16        # Forward pass the data through the model
17        output = model(data)
18        init_pred = output.max(1, keepdim=True)[1] # get the index of the max log-probability
19
20        # If the initial prediction is wrong, don't bother attacking, just move on
21        if init_pred.item() != target.item():
22            continue
23
24        # Calculate the loss
25        loss = F.nll_loss(output, target)
26
27        # Zero all existing gradients
28        model.zero_grad()
29
30        # Calculate gradients of model in backward pass
31        loss.backward()
32
33        # Collect ``datagrad``
34        data_grad = data.grad.data
```

获取这一批 test 数据的梯度，用于之后计算扰动图片

```
36        # Call FGSM Attack
37        perturbed_data = fgsm_attack(data, epsilon, data_grad)
38
39        # Re-classify the perturbed image
40        output = model(perturbed_data)
```

利用获得的梯度计算扰动图片，并使用现有模型进行预测

```

42     # Check for success
43     final_pred = output.max(1, keepdim=True)[1] # get the index of the max log-probability
44     if final_pred.item() == target.item():
45         correct += 1
46     # Special case for saving 0 epsilon examples
47     if (epsilon == 0) and (len(adv_examples) < 5):
48         adv_ex = perturbed_data.squeeze().detach().cpu().numpy()
49         adv_examples.append( (init_pred.item(), final_pred.item(), adv_ex) )
50     else:
51         # Save some adv examples for visualization later
52         if len(adv_examples) < 5:
53             adv_ex = perturbed_data.squeeze().detach().cpu().numpy()
54             adv_examples.append((init_pred.item(), final_pred.item(), adv_ex))

```

将预测的结果（概率）转变为离散的标记，并判断是否预测正确。若正确，correct 计数器加一。对于 episode=0（即无扰动的情況下），我们展示预测正确的前五张。若预测错误，correct 不用动，记录错误的前五张

```

56     # Calculate final accuracy for this epsilon
57     final_acc = correct/float(len(test_loader))
58     print("Epsilon: {} \t Test Accuracy = {} / {} = {}".format(epsilon, correct, len(test_loader), final_acc))
59
60     # Return the accuracy and an adversarial example
61     return final_acc, adv_examples

```

计算 acc 并返回 acc 和用于可视化的几组图

3. 分别对 默认给出的 $\epsilon = [0, .05, .08, .1, .15, .2, .25]$ 和自行修改的 ϵ 执行结果进行截图，并做简要说明。

```

⇒ Epsilon: 0      Test Accuracy = 9810 / 10000 = 0.981
   Epsilon: 0.05  Test Accuracy = 9426 / 10000 = 0.9426
   Epsilon: 0.08  Test Accuracy = 8936 / 10000 = 0.8936
   Epsilon: 0.1   Test Accuracy = 8510 / 10000 = 0.851
   Epsilon: 0.15  Test Accuracy = 6826 / 10000 = 0.6826
   Epsilon: 0.2   Test Accuracy = 4301 / 10000 = 0.4301
   Epsilon: 0.25  Test Accuracy = 2082 / 10000 = 0.2082

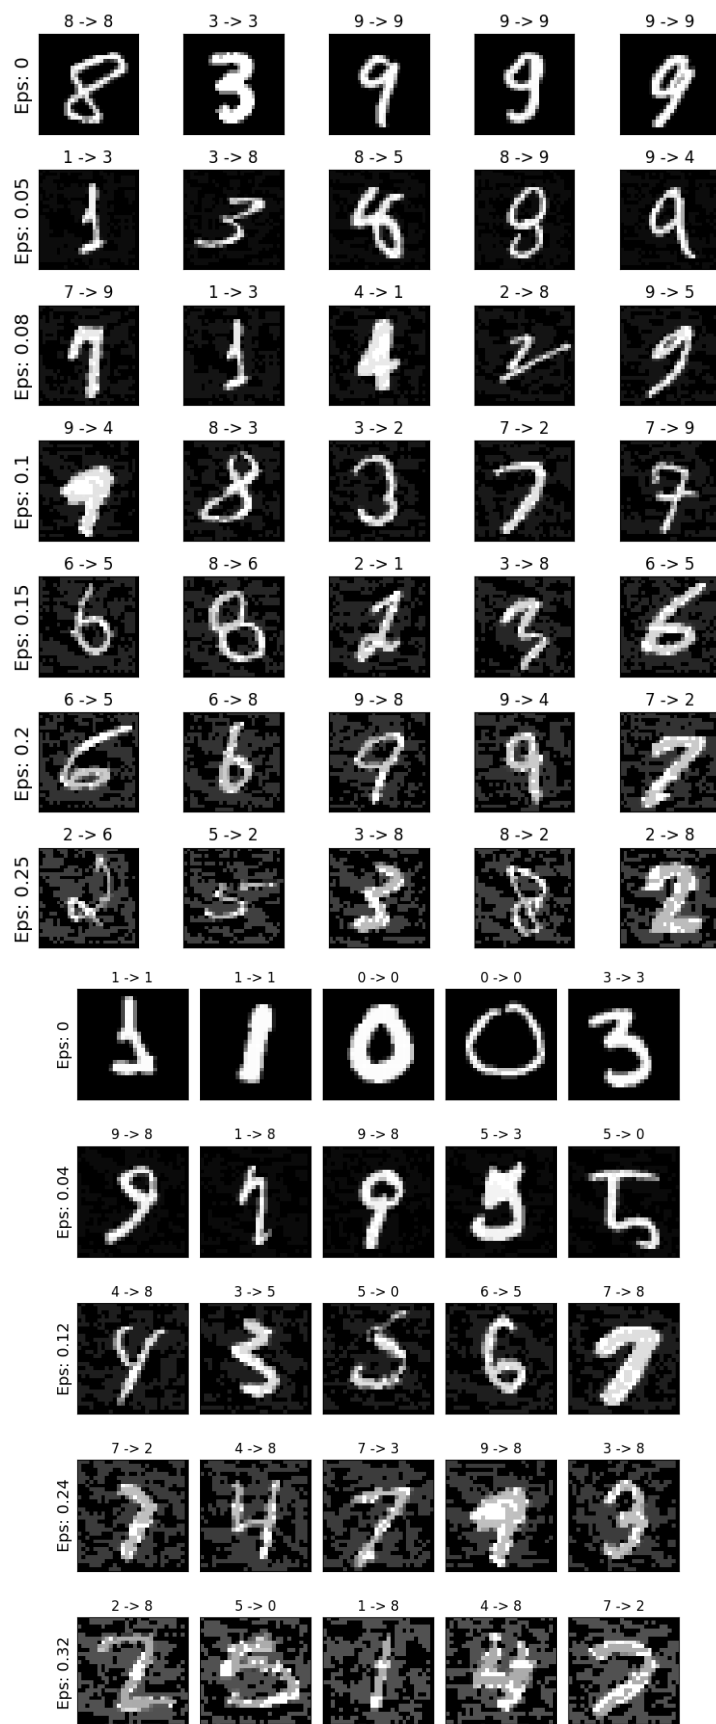
```

```

⇒ Epsilon: 0      Test Accuracy = 9810 / 10000 = 0.981
   Epsilon: 0.04   Test Accuracy = 9523 / 10000 = 0.9523
   Epsilon: 0.12   Test Accuracy = 7943 / 10000 = 0.7943
   Epsilon: 0.24   Test Accuracy = 2458 / 10000 = 0.2458
   Epsilon: 0.32   Test Accuracy = 603 / 10000 = 0.0603

```

随着 epsilon 的增加，acc 不断下降。尤其是 epsilon 超过 0.15 之后，强烈的扰动让机器难以分辨图像。在 epsilon 达到 0.3 左右的时候，分类器和随机预测的效果并无差别。观察下面的可视化图像可以看出，在如此强烈的扰动下，虽然人眼还能分辨笔迹，但很多数字的重要特征已被噪音淹没或者和别的数字混杂了



4. 任意选择一个扩展任务将完成的解决方案、代码和测试结果进行说明。

选择防御对抗样本攻击，这意味着我们需要生成对抗样本和其正确的 label 对，重新投入并训练我们的模型

```
1 retrained_model_path = 'data/retrained_model.pth'
2
3 retrained_model = Net().to(device)
4
5 retrained_model.load_state_dict(torch.load(retrained_model_path, map_location='cpu'))
```

重新加载一个网络的参数，这个保存的网络是从同样的 pretrained model 上开始训练的，只是后来我迭代训练了几次，就用新的保存的模型参数了

```
1 def adversarial_train(model, device, train_loader, optimizer, epsilon):
2     model.train()
3
4     for batch_idx, (data, target) in enumerate(train_loader):
5         data, target = data.to(device), target.to(device)
6         data.requires_grad = True
7
8         output = model(data)
9         loss = F.nll_loss(output, target)
10
11        model.zero_grad()
12        loss.backward()
13        data_grad = data.grad.data
14
15        perturbed_data = fgsm_attack(data, epsilon, data_grad)
16
17        combined_data = torch.cat([data.detach(), perturbed_data.detach()], dim=0)
18        combined_target = torch.cat([target, target], dim=0)
19
20        output = model(combined_data)
21        loss = F.nll_loss(output, combined_target)
22
23        optimizer.zero_grad()
24        loss.backward()
25        optimizer.step()
26
27        if batch_idx % 100 == 0:
28            print(f'Train Batch: {batch_idx}\tloss: {loss.item():.6f}')
```

类比之前的 test(), 我们需要加载 dataloader 中的数据对, 首先在模型上得到梯度, 计算出对抗样本, 并和原本的样本合并, 标签即为原本样本的标签自己 concatenate 一次, 重新投入训练

```

[19] 1 mnist_mean = 0.1307
      2 mnist_std = 0.3081
      3
      4 train_loader = torch.utils.data.DataLoader(
      5     datasets.MNIST(
      6         './data', train=True, download=True,
      7         transform=transforms.Compose([
      8             transforms.ToTensor(),
      9             transforms.Normalize((mnist_mean,), (mnist_std,))
     10         ])
     11     ),
     12     batch_size=64, shuffle=True
     13 )

[20] 1 import torch.optim as optim
      2
      3
      4 optimizer = optim.Adam(retrained_model.parameters(), lr=0.001)

[26] 1 for eps in epsilons:
      2     adversarial_train(retrained_model, device, train_loader, optimizer, eps)

```

准备好训练集和 optimizer，对每个 episode 进行训练。因为我想随时手动停止训练和观察数据就没有设置 epoch，而是自己手动迭代

```

[分] 1 accuracies = []
      2 examples = []
      3
      4 # Run test for each epsilon
      5 for eps in epsilons:
      6     acc, ex = test(retrained_model, device, test_loader, eps)
      7     accuracies.append(acc)
      8     examples.append(ex)

Epsilon: 0      Test Accuracy = 9496 / 10000 = 0.9496
Epsilon: 0.05   Test Accuracy = 9215 / 10000 = 0.9215
Epsilon: 0.08   Test Accuracy = 8886 / 10000 = 0.8886
Epsilon: 0.1    Test Accuracy = 8766 / 10000 = 0.8766
Epsilon: 0.15   Test Accuracy = 7949 / 10000 = 0.7949
Epsilon: 0.2    Test Accuracy = 7017 / 10000 = 0.7017
Epsilon: 0.25   Test Accuracy = 5945 / 10000 = 0.5945

```

用同样的方式查看 test 效果，可以看到，对轻扰动和无扰动的分类效果略有下降，但是对于强扰动后的图像分类正确率有明显上升。虽然这个正确率并未达到一个很好的结果，但这告诉我们我们有办法通过进一步的工作，如数据增强等方法来达到更好的分类效果

二、实验中遇到的问题和解决方法

实验比较简单，并没有遇到什么问题

三、本次实验的收获和建议

实验很有趣，虽然接触过很多神经网络图像分类任务，但第一次体验对抗样本攻击。从对抗样本的攻防中我进一步理解的数据的重要性，给我在数据预处理方面的启发